

Universität Paderborn  
Institut für Informatik  
Prof. Dr. Stefan Böttcher

Proseminar Datenkompression – WS 2016/2017

# Linear-Time Suffix-Sorting

Clemens Damke

Matrikelnummer 7011488



## Inhaltsverzeichnis

<b>1 Problemstellung</b>	<b>5</b>
1.1 Was ist ein Suffixarray? . . . . .	5
1.2 Einsatzgebiete von Suffixarrays . . . . .	5
<b>2 Ansätze zur Suffixarray-Konstruktion</b>	<b>6</b>
2.1 Naiver Ansatz . . . . .	6
2.2 Überblick über bisherige Linearzeitansätze . . . . .	6
<b>3 Der GSACA-Algorithmus</b>	<b>7</b>
3.1 Grundlegende Konzepte . . . . .	7
3.1.1 Induziertes Sortieren . . . . .	7
3.1.2 Gruppenkontext . . . . .	7
3.2 Die zwei Phasen von GSACA . . . . .	8
3.2.1 Phase 1 . . . . .	9
3.2.2 Phase 2 . . . . .	12
<b>4 Performanceanalyse</b>	<b>12</b>
<b>5 Fazit</b>	<b>12</b>
<b>Literaturverzeichnis</b>	<b>12</b>





# 1 Problemstellung

Diese Proseminar-Arbeit beschreibt den GSACA-Algorithmus. Hierbei handelt es sich um den ersten rekursionsfreien Linearzeitalgorithmus zur Konstruktion von Suffixarrays.

Im Folgenden wird zunächst erörtert, was Suffixarrays sind und wozu sie benutzt werden.

## 1.1 Was ist ein Suffixarray?

Das Suffixarray  $SA$  einer Zeichenkette  $S$  ist definiert als die lexiographisch aufsteigend sortierte Folge aller Suffixe von  $S$ .

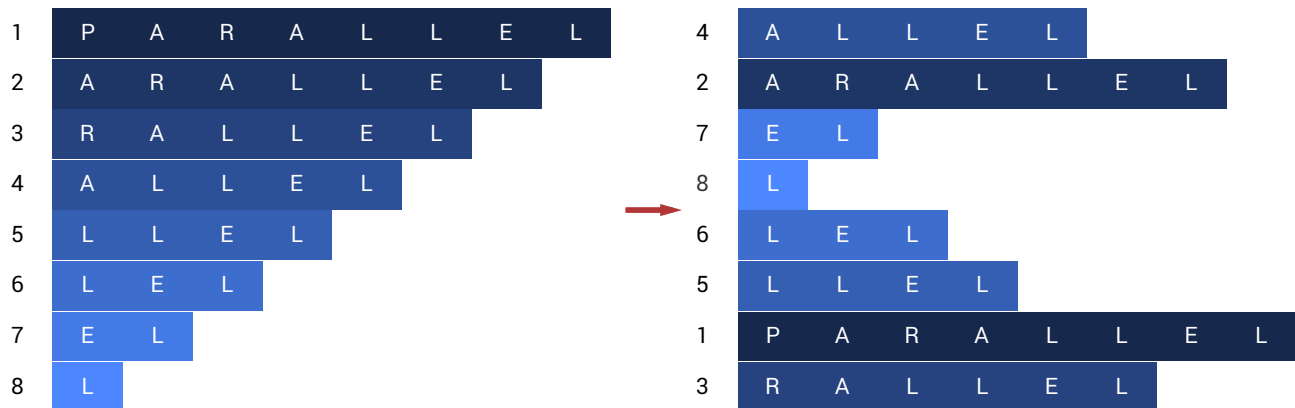


Abbildung 1: Suffixarray für  $S = \text{'parallel'}$

Um Speicher zu sparen wird  $SA$  allerdings nicht als Folge der Suffix-Zeichenketten, sondern als Folge der Startpunkte der Suffixe repräsentiert. Für  $S = \text{'parallel'}$  wäre also  $SA = (4, 2, 7, 8, 6, 5, 1, 3)$ . Formal bedeutet dies:

$$\begin{aligned}
 \Sigma &:= \text{streng total geordnetes endliches Alphabet} \\
 S &:= \text{Eingabezeichenkette} = (S[1], \dots, S[n]) \in \Sigma^n, |S| := n \in \mathbb{N} \\
 S[i..j+1] &:= S[i..j] := (S[i], \dots, S[j]) \\
 S_i &:= i\text{-ter Suffix von } S = S[i..n] \\
 S \sqsubseteq T &: \Leftrightarrow S \text{ ist Präfix von } T \Leftrightarrow S = T[1..|S|] \\
 S <_{lex} T &: \Leftrightarrow (\exists i : S[i] < T[i] \wedge S[1..i] = T[1..i]) \vee (|S| < |T| \wedge S \sqsubseteq T) \\
 SA &:= \text{Permutation von } \{1, \dots, |S|\}, \text{ sodass } \forall i < j : S_{SA[i]} <_{lex} S_{SA[j]}
 \end{aligned}$$

## 1.2 Einsatzgebiete von Suffixarrays

Suffixarrays finden in vielen Bereichen als Index-Datenstruktur Verwendung. Ein typisches Problem, dessen Lösung durch Suffixarrays beschleunigt werden kann, ist z. B. die Substringsuche. Bei dieser soll bestimmt werden, *ob* und *wenn ja, wo* in einem Text  $T$  ein Pattern  $P$  vorkommt. Ohne einen Index benötigt dieses Problem z. B. mit Knuth-Morris-Pratt  $\mathcal{O}(|T| + |P|)$ . Mit einem Suffixarray als Index



über  $T$  hingegen lassen sich Matches durch eine binäre Suche in  $\mathcal{O}(|P| \log |T|)$  finden. Da i. d. R.  $|P| \ll |T|$ , ist dies ein deutlicher Speedup, welcher z. B. in Datenbanksystemen für Volltextsuchen und in der Bioinformatik für das Suchen in DNA-Daten nützlich ist.

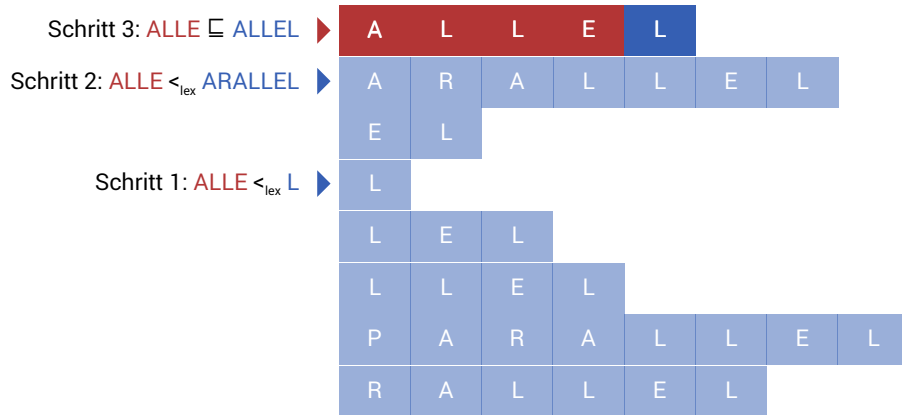


Abbildung 2: Substringsuche mit  $P = \text{'alle'}$  und  $T = \text{'parallel'}$

Ein weiteres Einsatzgebiet für Suffixarrays ist als Suchstruktur für das Sliding Window in Implementationen des LZ77-Kompressionsalgorithmus.

## 2 Ansätze zur Suffixarray-Konstruktion

Nachdem nun der Begriff des Suffixarrays definiert wurde, wird im Folgenden betrachtet wie sich dieses prinzipiell algorithmisch berechnen lässt.

### 2.1 Naiver Ansatz

Da es sich bei der Suffixarray-Berechnung im Wesentlichen um ein Sortierproblem handelt, liegt die Idee nahe dies mit einem allgemeinen Sortierverfahren zu lösen. Dazu bietet sich z. B. der Quicksort-Algorithmus an. Im average case wären dann  $\mathcal{O}(n \log n)$  Vergleiche notwendig. Für den lexikographischen Vergleich zweier Suffixe müssen wiederum bis zu  $\mathcal{O}(n)$  Zeichen miteinander verglichen werden. Insgesamt ergibt sich also eine Laufzeit von  $\mathcal{O}(n^2 \log n)$ . Dies ist weit von der angestrebten  $\mathcal{O}(n)$ -Laufzeit entfernt. Allgemeine Sortierverfahren sind daher für die Suffixarray-Konstruktion unbrauchbar.

### 2.2 Überblick über bisherige Linearzeitansätze

Es sind bereits zahlreiche Linearzeitalgorithmen zur Konstruktion von Suffixarrays bekannt. Allerdings sind all diese Verfahren rekursiv. Das bedeutet, dass sie neben der Eingabe und evtl. Hilfsdatenstrukturen zudem mindestens  $\mathcal{O}(\log n)$  Speicher für die Stackframes der rekursiven Aufrufe benötigen.

Zwei dieser rekursiven Linearzeitalgorithmen sind der Algorithmus von Skew und der SA-IS-Algorithmus. Skew ist primär wegen seiner Kompaktheit und Eleganz interessant. SA-IS basiert auf

dem Konzept der induzierten Sortierung und gehört zu den schnellsten bekannten SACAs (suffix array construction algorithms). Obwohl es sich bei beiden um Linearzeitalgorithmen handelt, sind die konstanten Faktoren in Implementationen von SA-IS deutlich geringer.

	Skew	SA-IS	GSACA
Art	rekursiv	rekursiv	iterativ
Zeit	$\mathcal{O}(n)$	$\mathcal{O}(n)$	$\mathcal{O}(n)$
Speicher	$\mathcal{O}(\log n) + \max 24n$	$\mathcal{O}(\log n) + \max 2n$	$\mathcal{O}(1) + ?$

Tabelle 1: Vergleich von Skew, SA-IS und GSACA

## 3 Der GSACA-Algorithmus

Im Rest dieser Arbeit wird es um den GSACA-Algorithmus (greedy suffix array construction algorithm) gehen, welcher der erste bekannte rekursionsfreie Linearzeit-SACA ist. Skew und SA-IS werden dabei als Referenzalgorithmen dienen, mit denen GSACA verglichen wird.

### 3.1 Grundlegende Konzepte

Um den GSACA-Algorithmus zu verstehen, ist es hilfreich zuerst eine Intuition dafür zu geben, wie so Suffixe überhaupt in  $\mathcal{O}(n)$  sortiert werden können. Im Gegensatz zu allgemeinen Sortierverfahren mit  $\mathcal{O}(n \log n)$  Vergleichen, lassen sich hier offenbar Vergleiche sparen.

#### 3.1.1 Induziertes Sortieren

Der fundamentale Unterschied zwischen allgemeinen Sortierproblemen und der Suffixsortierung ist, dass aus der Ordnung von bestimmten Suffixen  $T(1) <_{lex} \dots <_{lex} T(n)$  die Ordnung anderer Suffixe  $G(1), \dots, G(n)$  induziert werden kann. Es muss dann also lediglich Zeit in Vergleiche der  $T$ -Suffixe investiert werden.

$$\begin{aligned}
 T &:= \{T(1), \dots, T(n)\}, \text{ sodass } T(1) <_{lex} \dots <_{lex} T(n) \\
 G &:= \{G(1), \dots, G(n)\}, \text{ sodass } \exists P \in \Sigma^* \forall i : G(i) = P T(i) \\
 &\implies G(1) <_{lex} \dots <_{lex} G(n)
 \end{aligned}$$

Um diese Implikation nutzen zu können, müssen Suffixe also mit einem geschickt gewählten Präfix  $P$  einer Gruppe  $G$  zugeordnet werden. GSACA tut genau das.

#### 3.1.2 Gruppenkontext

Für die Gruppierung von Suffixen benutzt GSACA das Konzept des *Gruppenkontextes*, welcher als der gemeinsame Präfix  $P$  aller Suffixe in einer Gruppe dient. Dieser Begriff wird im Folgenden näher



betrachtet. Es wird dabei angenommen, dass es sich bei der Eingabe  $S$  um einen *nullterminierten* String handelt.

$S$  nullterminiert  $:\Leftrightarrow S[n] = \$ \wedge S[1..n] \in (\Sigma \setminus \{\$\})^*$ , mit  $\$ \in \Sigma, \forall \sigma \in \Sigma \setminus \{\$\} : \$ < \sigma$   
zur Erinnerung:  $S_i := i$ -ter Suffix von  $S = S[i..n]$

$$\hat{i} := \min\{j \in \{i, \dots, n\} : S_j <_{lex} S_i\}$$

Gruppenkontext von  $S_i := S[i..\hat{i}]$

Gruppe von  $S_i := \{S_j : \text{Gruppenkontext } S_i = \text{Gruppenkontext } S_j\}$




Abbildung 3: Veranschaulichung des Gruppenkontextes von  $S_2$  für  $S = \text{'parallel\$'}$

Der Gruppenkontext eines Suffixes  $S_i$  ist also dessen erster Präfix auf den ein lexiographisch kleinerer Suffix von  $S_i$  folgt.


### 3.2 Die zwei Phasen von GSACA

Mit dem Konzept des induzierten Sortierens und dem des Gruppenkontextes zur Gruppierung von Suffixen, lässt sich GSACA nun als ein in zwei Phasen ablaufender Algorithmus verstehen.

In der *ersten Phase* werden alle Suffixe der Eingabe gemäß ihrer Gruppenkontexte in Gruppen zusammengefasst. Die resultierenden Gruppen werden dabei nach Gruppenkontext aufsteigend sortiert zurückgegeben.

Diese sortierte Folge von Gruppen wird nun als Eingabe der *zweiten Phase* verwendet. Da die Gruppen untereinander bereits nach ihrem Kontext sortiert wurden und ein Kontext jeweils Präfix der Suffixe seiner Gruppe ist, müssen die Suffixe in dieser Phase lediglich innerhalb ihrer jeweiligen Gruppe geordnet werden. Für das Ordnen der Suffixe innerhalb einer Gruppe wird induziertes Sortieren genutzt.




Abbildung 4: Ausgabe beider Phasen für  $S = \text{'parallel\$'}$ , Farben kennzeichnen Gruppen

Das Ergebnis der zweiten Phase ist das gesuchte Suffixarray. Ziel ist es nun beide Phasen ohne Rekursion als  $\mathcal{O}(n)$ -Algorithmen zu formulieren.

### 3.2.1 Phase 1

**Intuition** GSACA berechnet die Gruppen, indem jedem Suffix zu Anfang ein vorläufiger einstelliger Gruppenkontext zugewiesen wird. Diese vorläufigen Kontexte werden dann sukzessive erweitert, bis am Ende jeder Suffix den korrekten Gruppenkontext hat.

Konkret bedeutet dies, dass der Kontext jedes Suffixes  $S_i$  zu Beginn auf  $S[i]$  gesetzt wird. Da das Eingabealphabet  $\Sigma$  als konstant angenommen wird, können die Suffixe nun z. B. mit einem Bucketsort in  $\mathcal{O}(n)$  gemäß ihres Kontextes in eine aufsteigende Folge von vorläufigen Gruppen sortiert werden.

Abbildung 5: Ergebnis des Bucketsorts für  $S = \text{'parallel\$'}$ 

Manche der sich ergebenden Gruppen müssen nun durch Kontexterweiterungen aufgespalten werden. Dies geschieht indem von hinten nach vorne, i. e. von großem zu kleinem Kontext, über die Gruppen iteriert wird. Für jeden Suffix der aktuell iterierten Gruppe wird nun der sog. *prev*-Pointer berechnet.

$$\text{prev}(i) := \max\{j \in \{1, \dots, i\} : \text{akt. Gruppenkontext } S_j <_{\text{lex}} \text{akt. Gruppenkontext } S_i\}$$

$\text{prev}(i)$  ist verwandt mit der  $\hat{i}$ -Funktion. Statt des *nächst kleineren* Suffix, gibt *prev* allerdings den ersten *vorherigen* Suffix aus einer Gruppe mit *kleinerem aktuellen Kontext* zurück. Aus dieser Verwandtschaft folgt, dass  $j = \text{prev}(i) < i < \hat{i} \leq \hat{j}$  gilt. Das bedeutet, dass der Gruppenkontext von  $S_i$  Teil



des Gruppenkontextes von  $S_{prev(i)}$  ist. Es lässt sich zeigen, dass durch das Iterieren von großen zu kleinen Gruppen in jeder Iteration für jeden Suffix  $S_i$  der gerade iterierten Gruppe gilt:

$$concat(\text{aktueller Kontext } S_{prev(i)}, \text{ aktueller Kontext } S_i) \subseteq \text{Gruppenkontext } S_{prev(i)}$$

Deshalb kann der aktuelle Kontext von  $S_{prev(i)}$  um den aktuellen Kontext von  $S_i$  erweitert werden. Der neue erweiterte Kontext von  $S_{prev(i)}$  ist nun lexiographisch größer als vorher,  $S_{prev(i)}$  wird deshalb aus seiner bisherigen Gruppe  $G$  entfernt und in eine neue Gruppe  $G'$  eingefügt, die in der Gruppenfolge hinter  $G$  eingeordnet wird.




Abbildung 6: Iteration 1 von Phase 1: Kontexterweiterung mit Suffixen der R-Gruppe

Bei der soeben beschriebenen Kontexterweiterung kann nun folgender Fall eintreten:  $k > 1$  der Suffixe der gerade iterierten Gruppe  $G$  haben den selben  $prev$ -Pointer-Wert  $p$ . In dieser Situation wird der Kontext von  $p$   $k$ -mal um den  $G$ -Kontext erweitert. Durch einen Widerspruchsbeweis lässt sich nämlich leicht zeigen, dass der  $G$ -Kontext dann  $k$ -mal direkt hintereinander auf den  $p$ -Kontext folgt. Der Beweis wird hier ausgelassen.




Abbildung 7: Iteration 3 von Phase 1: Doppelte Kontexterweiterung mit Suffixen der L-Gruppe

Nachdem so über alle Gruppen iteriert wurde, sind die aktuellen Kontexte aller Gruppen gleich den finalen Gruppenkontexten. Insgesamt kann jeder Suffix höchstens einmal zur Kontexterweiterung eines anderen Suffixes benutzt werden und jede Kontexterweiterung benötigt konstante Zeit.

Für diesen Teil von Phase 1 ergibt sich also eine Laufzeit von  $\mathcal{O}(n)$ . Dabei wurde die *prev*-Pointer-Berechnung allerdings noch nicht berücksichtigt. Ein naiver Ansatz zum Berechnen von  $prev(i)$  ist, rückwärts von  $i - 1$  bis 1 zu iterieren und beim ersten Suffix aus einer kleineren aktuellen Gruppe als der von  $S_i$  zu stoppen. Mit dieser Strategie benötigt die *prev*-Berechnung  $\mathcal{O}(n)$  Schritte. Da  $n$  Pointer zu berechnen sind, würde Phase 1 so also  $\mathcal{O}(n^2)$  Schritte brauchen.

Eine Optimierung ist notwendig: *Pointer-Jumping*. Statt über alle  $i - 1$  vorherige Suffixe zu iterieren, werden Suffixe übersprungen, die gar nicht als *prev*-Pointer in Frage kommen. Konkret wird beim Pointer-Jumping nicht über  $i - 1, i - 2, i - 3, \dots$  sondern über  $i - 1, prev(i - 1), prev^2(i - 1), \dots$  iteriert, wobei  $prev^k(i) := \underbrace{prev(\dots prev(i))}_{k \text{ mal}}$ .

Es wird also der Kette der *prev*-Pointer ab Suffix  $S_{i-1}$  gefolgt. Dies funktioniert, da alle Suffixe zwischen  $prev^{k+1}(i - 1)$  und  $prev^k(i - 1)$  per Definition von *prev* größer sein müssen als  $prev^k(i - 1)$  und somit unmöglich als Wert von  $prev(i)$  in Frage kommen.




Abbildung 8: Iteration 4 von Phase 1: *prev*-Pointer-Berechnung in der *EL*-Gruppe

Durch das Pointer-Jumping können die *prev*-Pointer-Gesamtkosten in allen Gruppeniteration von Phase 1 von  $\mathcal{O}(n^2)$  auf  $\mathcal{O}(n)$  reduziert werden. Dies liegt daran, dass jeder *prev*-Pointer nur höchstens einmal für einen Pointer-Jump benutzt wird. Insgesamt können also höchstens  $n$  Pointer-Jumps stattfinden. Der Beweis wird hier ausgelassen.



Abbildung 9: Ergebnis von Phase 1: Alle Suffixe sind gemäß ihrer Kontexte gruppiert und sortiert



3.2.2 Phase 2

**Intuition** In Phase 2 müssen die Suffixe nun innerhalb ihrer Gruppen geordnet werden. Hierzu wird zuerst das erste Element des gesuchten Suffixarrays bestimmt. Da die Gruppenkontexte geschickt definiert wurden, ermöglicht dies das Induzieren des zweiten Elements des Suffixarrays, woraus wiederum die Position des dritten Elements folgt, usw.

test

4 Performanceanalyse

	Skew	SA-IS	GSACA
Art	rekursiv	rekursiv	iterativ
Zeit	$\mathcal{O}(n)$	$\mathcal{O}(n)$	$\mathcal{O}(n)$
Speicher	$\mathcal{O}(\log n) + \max 24n$	$\mathcal{O}(\log n) + \max 2n$	$\mathcal{O}(1) + 12n$

Tabelle 2: Vergleich von Skew, SA-IS und GSACA

5 Fazit

test

Literatur